

ARUS

Energy-Aware Compute Intelligence

Compute Smarter. Waste Less Energy

AI-driven workload placement for more energy-efficient compute

Ringkasan — Gambaran Utama ARUS

ARUS mengubah penempatan workload dari keputusan berbasis ketersediaan menjadi keputusan berbasis efisiensi energi.

Masalah Saat Ini

- Workload sering dijalankan berdasarkan mesin yang kosong, mesin tercepat, atau kebiasaan operator
- **Energi total** hingga pekerjaan selesai belum menjadi pertimbangan utama
- Akibatnya, penggunaan listrik dan biaya komputasi berpotensi **tidak efisien**

Arus Solution

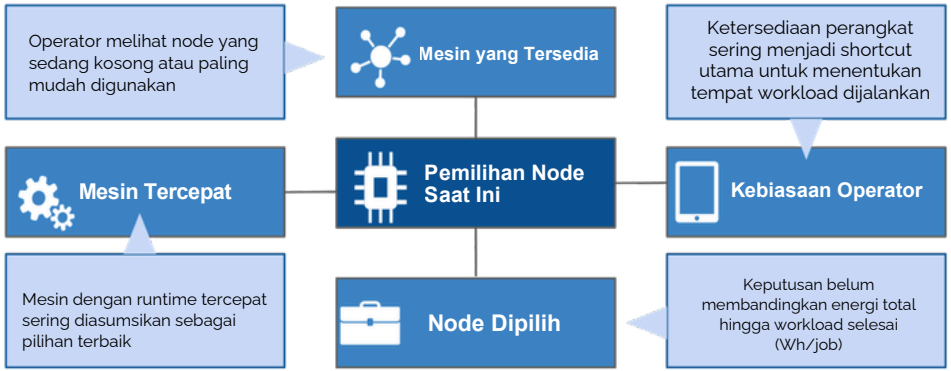
- ARUS mempelajari hubungan antara karakteristik workload, hardware, dan kondisi node
- ARUS memprediksi runtime dan konsumsi energi pada setiap node
- Sistem merekomendasikan node feasible dengan prediksi energi terendah
- Efisiensi energi tetap dijaga tanpa melanggar batas performa

Masalah — Pemilihan Node Belum Mempertimbangkan Efisiensi Energi

Workload yang sama dapat membutuhkan waktu dan energi berbeda pada setiap node, tetapi pemilihannya masih sering berdasarkan ketersediaan atau kecepatan, bukan total energi hingga pekerjaan selesai.

Pemilihan node masih berbasis ketersediaan, bukan efisiensi energi

Bagaimana node dipilih saat ini

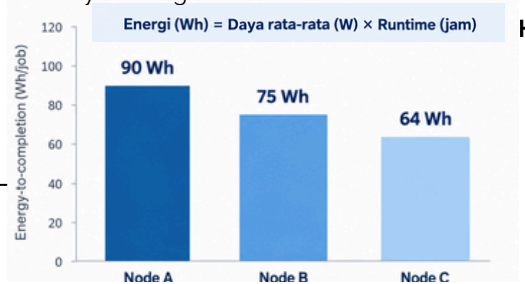


Daya lebih rendah belum tentu berarti energi total lebih rendah

Energi hingga workload selesai dipengaruhi oleh daya sekaligus runtime

Daya rendah ≠ energi total lebih rendah

Mesin yang lebih hemat daya dapat mengonsumsi lebih banyak energi jika membutuhkan waktu jauh lebih lama.

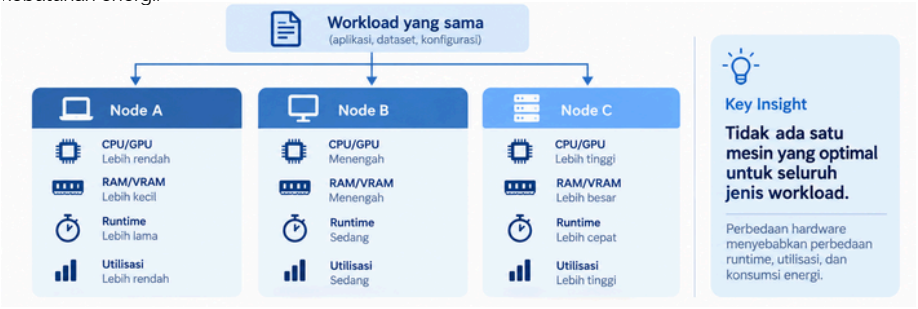


Key Insight

Efisiensi komputasi tidak ditentukan oleh daya rata-rata saja, melainkan oleh kombinasi daya dan runtime pada tiap node.

Workload yang sama dapat menghasilkan runtime dan konsumsi energi yang berbeda pada setiap node

Perbedaan CPU, GPU, RAM/VRAM, dan kondisi mesin memengaruhi runtime, utilisasi, serta kebutuhan energi.



Implikasinya: mesin yang paling cepat atau paling kuat belum tentu menjadi pilihan paling efisien untuk setiap node. Mengandalkan satu asumsi dalam memilih node dapat menghasilkan placement yang tidak optimal.

Hasil eksekusi belum digunakan untuk memperbaiki placement berikutnya

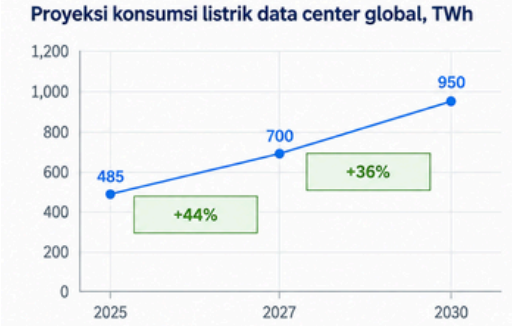


Masalah — Efisiensi Energi Komputasi Menjadi Semakin Mendesak

Pertumbuhan AI, konsumsi listrik compute, dan kompleksitas hardware membuat keputusan placement semakin penting.

Permintaan listrik untuk komputasi meningkat cepat

Pertumbuhan AI dan data center meningkatkan urgensi efisiensi energi compute

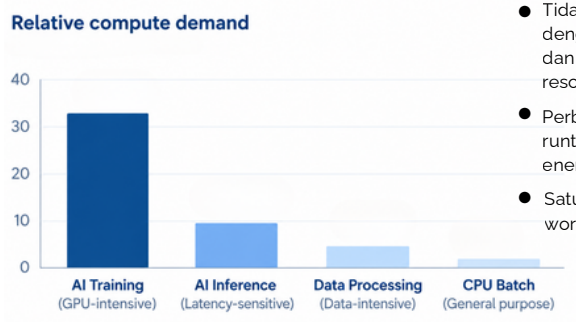


- Konsumsi listrik data center global diproyeksikan **hampir dua kali lipat**, dari sekitar 485 TWh pada 2025 menjadi 950 TWh pada 2030.
- Pertumbuhan tersebut semakin didorong oleh **AI dan workload komputasi intensif**, sehingga kebutuhan energi compute ikut meningkat.
- Ketika kebutuhan compute meningkat, efisiensi energi per workload menjadi semakin strategis untuk menahan pertumbuhan konsumsi listrik dan biaya.

Source:IEA (2024), Electricity 2024 - Analysis and forecast to 2030

AI membuat karakter workload semakin beragam

AI training, inference, data processing, dan CPU batch memiliki profil komputasi yang berbeda.



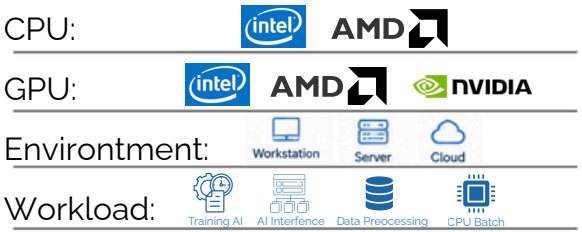
- Tidak semua workload membebani hardware dengan cara yang sama training, inference, dan data processing memiliki kebutuhan resource berbeda.
- Perbedaan karakter workload menghasilkan runtime, utilisasi CPU/GPU, dan konsumsi energi yang berbeda pada setiap mesin.
- Satu node tidak selalu optimal untuk semua workload

Fleet komputasi semakin heterogen

Organisasi menjalankan workload pada kombinasi CPU, GPU, RAM, dan generasi hardware yang berbeda

KEY INSIGHT

Tidak ada satu mesin yang optimal untuk seluruh jenis workload.
Perbedaan CPU, GPU, memori, dan konfigurasi hardware membuat setiap node memiliki karakter runtime dan konsumsi energi yang berbeda



Efisiensi energi berdampak langsung pada biaya dan emisi

Setiap peningkatan efisiensi workload placement dapat membantu menekan konsumsi listrik, biaya operasional, dan jejak emisi.



Dengan demikian, optimasi placement tidak hanya meningkatkan efisiensi teknis, tetapi juga memberikan dampak ekonomi dan lingkungan.

Solusi — Pemilihan Node Berbasis Efisiensi Energi

ARUS memperkirakan waktu penyelesaian dan kebutuhan energi pada setiap node, lalu merekomendasikan pilihan yang paling efisien tanpa mengabaikan kebutuhan performa.

ARUS Membaca Workload dan Kondisi Setiap Node

Energy-Aware Decision Engine

Sebelum workload dijalankan, ARUS memahami karakter pekerjaan dan kondisi setiap mesin untuk memperkirakan bagaimana workload tersebut akan berjalan pada masing-masing node.

1. Memahami karakter workload

ARUS membaca jenis workload, parameter eksekusi, dan kebutuhan resource untuk memahami karakter pekerjaan yang akan dijalankan.

2. Mengenali karakter setiap node

Setiap node memiliki konfigurasi CPU, GPU, RAM/VRAM, dan kemampuan hardware yang berbeda. ARUS menggunakan informasi tersebut untuk membandingkan setiap kandidat node.

3. Membaca kondisi node saat ini

Sebelum placement dilakukan, ARUS mempertimbangkan availability dan kondisi resource tiap node agar keputusan tidak hanya bergantung pada spesifikasi hardware di atas kertas.

Data tersebut menjadi dasar ARUS untuk memperkirakan waktu penyelesaian dan kebutuhan energi pada setiap node yang tersedia.

Bagaimana ARUS Memilih Node?

Membandingkan Setiap Kandidat Node

ARUS memperkirakan waktu penyelesaian dan energi yang dibutuhkan jika workload dijalankan pada masing-masing node.

Memilih Komputer yang Mampu Menjalankan Workload

ARUS mengecek apakah setiap komputer memiliki CPU, GPU, RAM, dan kapasitas yang cukup untuk menjalankan workload sesuai kebutuhan.

Merekomendasikan Pilihan Paling Efisien

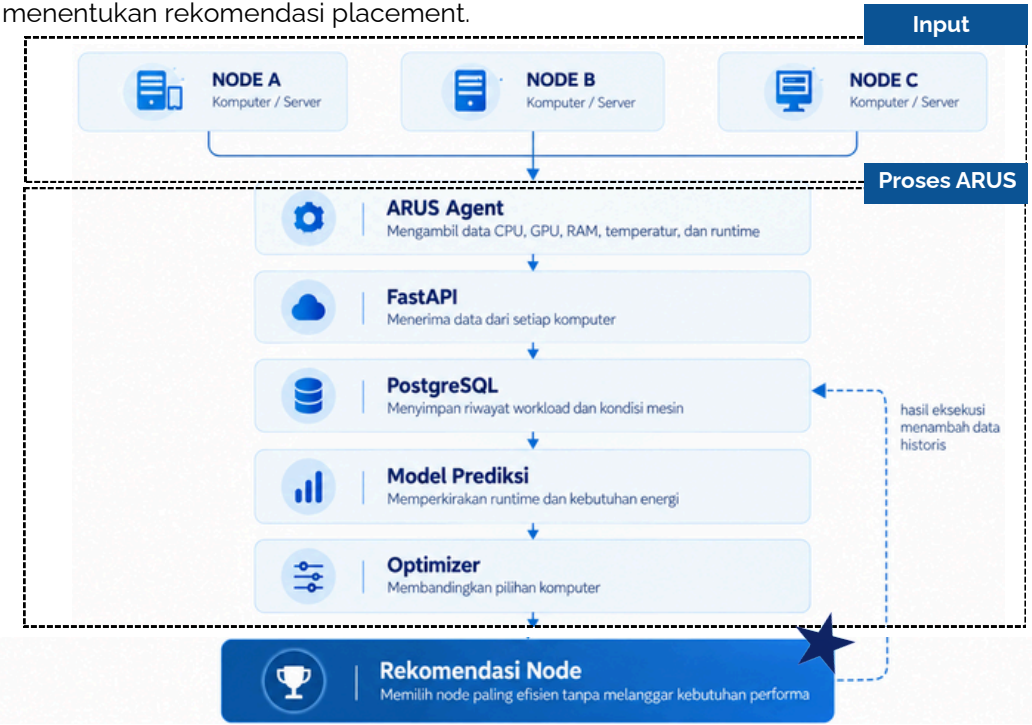
Dari node yang memenuhi kebutuhan, ARUS merekomendasikan pilihan dengan kebutuhan energi paling rendah sambil tetap menjaga performa.

MVP & Validasi — Arsitektur Sistem ARUS

ARUS menghubungkan tiga komputer, pengumpulan data, database, model prediksi, dan sistem rekomendasi dalam satu alur kerja untuk menentukan penempatan workload yang lebih efisien.

Arsitektur Inti ARUS

Data dari beberapa komputer dikumpulkan, dipelajari, lalu digunakan untuk menentukan rekomendasi placement.



Teknologi yang Digunakan

ARUS dibangun dengan teknologi ringan dan open-source agar MVP dapat dikembangkan serta diuji dengan cepat.

Fungsi	Teknologi
Agent & Monitoring	Python · psutil · NVML
API	FastAPI
Database	PostgreSQL
Model Prediksi	scikit-learn
Dashboard	Streamlit
Deployment	Docker Compose

Mengapa Stack Ini Cocok untuk MVP?

Sebagian besar komponen bersifat open-source, dapat dijalankan pada infrastruktur yang sudah ada, dan mudah dikembangkan secara modular sehingga biaya validasi awal tetap rendah.

MVP & Validasi — Menguji Ketepatan Rekomendasi ARUS

Pengujian dilakukan pada beberapa node untuk membandingkan prediksi ARUS dengan hasil eksekusi aktual dan menilai ketepatan placement.

Setup Pengujian

- Workload yang sama dijalankan pada tiga node dengan spesifikasi hardware yang berbeda.
- Setiap pengujian mencatat waktu penyelesaian, penggunaan CPU/GPU/RAM, temperatur, serta estimasi kebutuhan energi
- Pengujian dilakukan berulang agar hasil antar-node dapat dibandingkan secara konsisten.
- Jika tersedia, power meter eksternal digunakan untuk membandingkan estimasi energi dengan pengukuran langsung.

Tujuan: Melihat bagaimana workload yang sama berperilaku pada hardware yang berbeda.

Apa yang Diukur?

- **Ketepatan prediksi waktu** seberapa dekat perkiraan ARUS dengan waktu aktual.
- **Ketepatan prediksi energi** seberapa dekat perkiraan energi dengan hasil pengujian.
- **Ketepatan rekomendasi node** apakah komputer yang direkomendasikan benar-benar menjadi pilihan yang lebih efisien.
- **Performa workload** penghematan energi tidak boleh mengorbankan kebutuhan performa.

Prediksi ARUS dibandingkan dengan hasil aktual setelah workload selesai dijalankan pada setiap node. Perbandingan ini digunakan untuk menilai ketepatan perkiraan waktu penyelesaian dan kebutuhan energi, sekaligus memastikan node yang direkomendasikan benar-benar memberikan efisiensi yang lebih baik tanpa mengganggu performa workload.

Apa yang Ingin Dibuktikan?

1 **— Hardware yang berbeda menghasilkan hasil yang berbeda**
Workload yang sama dapat membutuhkan waktu dan energi yang berbeda ketika dijalankan pada komputer yang berbeda.

2 **— ARUS dapat memperkirakan hasil sebelum workload dijalankan**
Prediksi runtime dan energi ARUS diharapkan mendekati hasil pengujian aktual.

3 **— ARUS dapat membantu memilih komputer yang lebih efisien**
Rekomendasi ARUS dibandingkan dengan cara sederhana seperti memilih komputer yang kosong atau paling cepat.

MVP dinilai berhasil jika ARUS dapat memberikan rekomendasi yang lebih efisien dengan tetap menjaga kebutuhan performa.

Teknologi & Pembeda — Posisi ARUS di Antara Sistem yang Ada

ARUS tidak menggantikan scheduler atau tools monitoring yang sudah ada, tetapi menambahkan rekomendasi placement berbasis efisiensi energi pada lingkungan komputasi heterogen

	Kubernetes / Slurm	Kepler	Carbon Aware SDK	ARUS	Mengapa Ini Penting
Penempatan Workload	✓	–	◐	✓	Menentukan komputer mana yang akan menjalankan pekerjaan.
Dukungan Hardware Heterogen	✓	◐	–	✓	CPU, GPU, dan memori yang berbeda dapat menghasilkan runtime dan penggunaan energi yang berbeda.
Pemantauan Energi	◐	✓	–	✓	Tanpa data energi, efisiensi antar-komputer sulit dibandingkan.
Total Energi Workload Sampai Selesai	◔	◔	–	✓	Mesin berdaya rendah belum tentu paling hemat jika membutuhkan waktu jauh lebih lama.
Pembelajaran dari Hasil Eksekusi	–	–	–	✓	Data pekerjaan sebelumnya dapat digunakan untuk memperbaiki prediksi dan keputusan berikutnya.

ARUS tidak hanya berfungsi sebagai alat monitoring atau scheduler, tetapi menghubungkan data workload, profil hardware, konsumsi energi, dan riwayat eksekusi menjadi dasar pengambilan keputusan placement yang lebih efisien dan sesuai dengan kebutuhan performa.

Teknologi & Pembeda — Keunggulan ARUS Tumbuh Bersama Penggunaan

Semakin sering ARUS digunakan, semakin kaya data dan pemahaman sistem terhadap hubungan workload, hardware, dan energi.

Data Operasional

Data yang Dikumpulkan

- ARUS merekam jenis workload, parameter eksekusi, dan kebutuhan resource dari setiap job
- Sistem juga menyimpan profil node, seperti CPU, GPU, RAM/VRAM, serta kondisi resource saat workload dijalankan
- Setiap hasil eksekusi menambah data runtime dan konsumsi energi aktual pada berbagai kombinasi workload dan hardware

Semakin banyak variasi eksekusi yang terekam, semakin kaya data ARUS untuk memahami hubungan antara workload, hardware, dan energi.

Pembelajaran Berkelanjutan

- Prediksi ARUS dibandingkan dengan hasil eksekusi aktual untuk melihat seberapa tepat rekomendasi yang diberikan
- Selisih antara prediksi dan hasil aktual digunakan untuk memperbaiki model secara bertahap
- Dengan proses ini, ARUS tidak berhenti pada aturan statis, tetapi terus belajar dari penggunaan nyata

Inilah yang membuat ARUS semakin akurat seiring waktu: semakin sering digunakan, semakin baik sistem memahami pola penempatan workload yang efisien.

Model & Kalibrasi

Prediksi Berbasis Data

- Model ARUS mempelajari hubungan antara karakter workload, spesifikasi node, kondisi mesin, runtime, dan konsumsi energi.
- Dari hubungan tersebut, ARUS memperkirakan waktu penyelesaian dan kebutuhan energi sebelum workload dijalankan.
- Semakin banyak data historis yang tersedia, model memiliki lebih banyak referensi untuk mengenali pola eksekusi pada berbagai kombinasi workload dan hardware.

Nilai model ARUS tidak hanya berasal dari algoritmanya, tetapi dari data operasional yang terus memperkaya pola yang dapat dipelajari.

Kalibrasi Spesifik Lingkungan

- Setiap kampus, lab, atau organisasi memiliki kombinasi hardware dan pola workload yang berbeda
- ARUS dapat dikalibrasi menggunakan data lokal sehingga prediksi semakin sesuai dengan karakter fleet pengguna.
- Model umum yang sama dapat menghasilkan rekomendasi yang berbeda ketika diterapkan pada lingkungan yang berbeda.

Semakin lama digunakan pada suatu lingkungan, semakin kontekstual model ARUS dalam memahami karakter workload dan hardware di tempat tersebut.

Integrasi Sistem

Terhubung dengan Infrastruktur Pengguna

- ARUS dapat dihubungkan dengan monitoring node, database, power meter, dan scheduler yang sudah digunakan.
- Integrasi membuat ARUS tidak berdiri sebagai tool terpisah, tetapi menjadi bagian dari alur kerja komputasi yang sudah berjalan.
- Semakin banyak komponen yang terhubung, semakin lengkap konteks yang tersedia untuk membuat rekomendasi placement.

Nilai ARUS meningkat ketika sistem terhubung langsung dengan data dan proses operasional pengguna.

Semakin Tertanam dalam Workflow

- Setelah digunakan dalam jangka waktu tertentu, ARUS akan menyimpan riwayat data, konfigurasi node, serta hasil kalibrasi yang spesifik terhadap lingkungan pengguna.
- Rekomendasi ARUS kemudian menjadi semakin terhubung dengan pola workload dan cara kerja organisasi tersebut.
- Perpindahan ke sistem lain berarti sebagian data historis, kalibrasi, dan integrasi workflow perlu dibangun kembali.

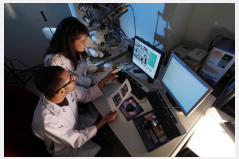
Seiring penggunaan, ARUS membangun data, kalibrasi, dan integrasi yang semakin spesifik terhadap lingkungan pengguna.

Dampak & Bisnis — Jalur Pasar ARUS dan Nilai yang Dihasilkan

ARUS memulai dari lingkungan validasi yang mudah diakses, lalu berkembang ke fleet komputasi dengan kebutuhan efisiensi energi, biaya, dan performa yang semakin besar.

Campus AI / Research Lab — VALIDATION

Validasi awal ARUS pada komputer dengan spesifikasi berbeda. Lingkungan kampus memberi akses eksperimen yang lebih mudah untuk membangun dataset workload, hardware, runtime, dan energi.



- Pengumpulan dataset awal
- Uji di beberapa spesifikasi komputer
- Kalibrasi prediksi runtime
- Kalibrasi estimasi energi

ARUS membangun dataset awal dan membuktikan apakah model dapat membedakan runtime serta kebutuhan energi pada hardware yang berbeda.

Private AI / GPU Lab — EARLY CUSTOMER

Workload AI, training, dan inference dijalankan lebih intensif. Efisiensi placement mulai berdampak pada penggunaan GPU, energi, dan waktu penyelesaian pekerjaan.



- Validasi pada workload AI nyata
- Evaluasi akurasi rekomendasi
- Perbandingan node CPU vs GPU
- Pengukuran efisiensi per job

ARUS mulai diuji pada workload nyata untuk melihat potensi penghematan energi tanpa mengorbankan kebutuhan performa.

Corporate GPU Fleet — COMMERCIAL

Banyak workstation atau server menjalankan workload secara berulang. Placement yang lebih efisien dapat mengurangi pemborosan energi sekaligus menjaga kebutuhan performa.



- Integrasi pada banyak node kerja
- Placement untuk workload berulang
- Efisiensi energi dan biaya
- Menjaga target performa

Placement yang lebih efisien dapat menekan konsumsi energi dan biaya operasional ketika workload dijalankan berulang dalam skala lebih besar.

Medium Compute Infrastructure — SCALE

ARUS berkembang ke lingkungan multi-node yang lebih besar dan dapat terhubung dengan monitoring maupun scheduler yang sudah digunakan.



- Integrasi dengan sistem yang ada
- Optimasi pada multi-node
- Monitoring berkelanjutan
- Pembelajaran dari histori eksekusi

ARUS berkembang menjadi lapisan optimasi multi-node yang dapat terintegrasi dengan monitoring dan scheduler yang sudah digunakan.

Dampak & Bisnis — Model Pendapatan dan Biaya Awal ARUS

ARUS menggunakan model software-first dengan biaya validasi awal yang ringan dan peluang pendapatan berulang seiring bertambahnya skala penggunaan.

Jalur Monetisasi ARUS

Pendapatan ARUS tumbuh seiring adopsi, dari pilot awal menuju subscription, lisensi, dan kerja sama enterprise.



ARUS memulai dari penerapan awal dengan hambatan yang rendah, lalu menghasilkan nilai yang lebih besar ketika jumlah node dan workload yang dikelola semakin bertambah.

Struktur Biaya MVP yang Ringan

- 3 komputer uji — menggunakan perangkat yang sudah tersedia
- Backend / server — menggunakan perangkat existing pada tahap MVP
- Software & database — menggunakan teknologi open-source
- Pengembangan — founder-built pada tahap awal
- Power meter — investasi berikutnya untuk meningkatkan kualitas validasi

Sebagian besar kebutuhan MVP berasal dari software dan aset yang sudah tersedia, sehingga ARUS dapat divalidasi tanpa investasi infrastruktur besar.

Roadmap ARUS — Dari Validasi hingga Scale-Up

ARUS dikembangkan secara bertahap dari validasi teknis menuju implementasi, komersialisasi, dan integrasi pada lingkungan komputasi yang lebih besar.

TARGET 2030

ARUS menjadi decision layer untuk placement workload berbasis efisiensi energi yang terintegrasi dengan monitoring dan scheduler pada lingkungan compute heterogen.



Dukungan Yang Dibutuhkan

1. Validasi Teknis

Akses pengujian untuk meningkatkan ketepatan model runtime dan energi.

2. Lingkungan Implementasi Nyata

Akses ke lab, GPU fleet, atau infrastruktur compute untuk menguji ARUS di luar testbed.

3. Dukungan Pendanaan

Untuk pengadaan instrumentasi, pengembangan MVP, serta implementasi awal pada lingkungan pengguna.

4. Mentorship & Partner Network

Pendampingan produk, bisnis, integrasi, serta akses ke calon pengguna dan mitra.

5. Instrumentasi Energi

Dukungan power meter dan alat ukur untuk memperoleh ground-truth konsumsi energi.